

國立成功大學

電機工程學系專題書面報告

基於 COS2A 之 Sentinel-2 影像高光譜重建與實驗分析

專題生：洪振歲
指導老師：林家祥

A. 研究動機與目標

雖然 Sentinel-2 衛星的多光譜影像全球可用且空間覆蓋廣，但其僅有 12 個光譜頻帶，且不同頻帶空間解析度不一致（10m、20m、60m），讓物質識別與精細應用受到限制。

AVIRIS，在物質識別上有極強辨識能力。但資料受限於載具航拍路徑，以及後端資料量龐大而不易處理等困難，難以普遍應用。

因此，本專題實作 COS2A 方法，將多光譜 Sentinel-2 資料轉換為 AVIRIS 級高光譜資料。並比較模型在模擬資料與真實 Sentinel-2 資料上的重建表現。

B. 基礎理論探討

I. 深度展開 (Deep Unfolding):

- 理論精神:

- 將原本的最佳化演算法(例如: ADMM)流程「顯式拆開」，設計成多層 (stage) 神經網路，每一層執行一個演算法步驟，兼具物理解釋性與神經網路的可訓練性。

II. CODE 理論 (Convex Optimization and Deep learning)

- 理論精神:

- 凸優化 (CO): 不太需要大規模資料，依靠嚴謹數學正則來加強解的解釋性與可控性。
- 深度學習 (DE): 能用少數資料預備出「粗解」，不需大量標註或很複雜架構。

- 核心公式:

$$Y^* = \arg \min_Y DF(Y|X) + \lambda REG(Y)$$

- 其中 DF 是資料擬合(如 $\|Y_S - DY_H\|_F^2$)，表現原始物理觀測的「逼近」 REG 是正則化(如 Q-quadratic-norm)，兩者都是 convex function，這類形式具有較好的可解釋性與穩定性，也比單純黑箱深度學習更容易控制解的結構。

III. 耦合非負矩陣分解 (Coupled Nonnegative Matrix Factorization, CNMF)

- 理論精神:

- 原論文透過 spectral-spatial duality，將 Sentinel-2 到 AVIRIS 的光譜超解析問題轉換為 coupled NMF 問題，並透過 fast convex algorithm 解出 endmember matrix (A) 與 abundance matrix (S)，最後得到重建結果 ($Y_H^* = A^* \cdot S^*$)。

- 本專題實作方式:

- 使用簡化版 CNMF 作為後處理方法。首先由深度展開網路產生粗略高光譜結果

(Y_{DE})，接著利用 Sentinel-2 的高解析度頻帶與光譜響應矩陣(D)，限制最終重建結果(AS) 同時接近 Y_{DE} 與原始 Sentinel-2 觀測資料。

- 核心公式:

$$\min_{A, S \geq 0} \omega_{de} \|Y_{DE} - AS\|_F^2 + \omega_{ms} \|\tilde{Y}_S - \tilde{D}AS\|_F^2 + \lambda \|S\|_1$$

其中 $\tilde{Y}_S$ 表示 Sentinel-2 中四個 10m 高解析度頻帶，第一項 ($\|Y_{DE} - AS\|_F^2$) 用來維持與深度網路輸出結果的一致性；第二項 ($\|\tilde{Y}_S - \tilde{D}AS\|_F^2$) 用來確保重建結果經由光譜響應矩陣($\tilde{D}$)降維後，仍能對應到 Sentinel-2 輸入影像；第三項 ($\|S\|_1$) 則用來限制 abundance matrix 的稀疏性，使每個像素主要由少數材質組成。

C. 研究方法與設計

本實作依據 COS2A 論文架構進行實作，主要流程包含資料前處理、模型重建、CNMF 後處理與結果評估。

■ 所使用工具: Python 3.9.21、MATLAB R2024a、ENVI 5.3、QGIS 3.40.10

Step1: 資料預處理

- 使用 AVIRIS 高光譜影像(172 波段、256 X 256 大小)作為 ground truth，並保留去除水氣吸收與損壞波段後的 172 個有效頻帶。輸入資料分為兩種：
 - **Simulation data**：由 AVIRIS 依照 Sentinel-2 波段範圍模擬產生。
 - **Real Sentinel-2 data**：使用真實 Sentinel-2 影像與 AVIRIS 影像配對。
 - **需要特別說明的是**，COS2A 論文指出，理想的訓練資料需為 AVIRIS 與 Sentinel-2 在相同空間場景、相同時間取得的 paired data；然而實際上，這類資料受到兩種感測器航拍軌跡、拍攝時間、空間解析度與前處理流程限制，取得難度極高。因此，**本專題使用的 real Sentinel-2 data 雖經過配對與篩選，但仍無法保證 AVIRIS 與 Sentinel-2 在時間與觀測條件上完全一致**。這項限制會影響後續 real data 的重建結果，也使其與 simulation data 的表現產生落差。
- 所有影像皆裁切為固定大小，並於訓練時隨機取樣 64×64 patches。
- 本專題在資料清理與篩選後，Simulation data 共使用 644 組影像；real Sentinel-2 data 共使用 428 組影像，train/validation/testing 比例與原論文設定相同，分別為 15:1:1 與 8:1:1。

Step2: 建立 COS2A 架構

- COS2A 的目標是由 Sentinel-2 多光譜影像 (Y_S) 重建出接近 AVIRIS 的高光譜影像 (Y_H)。
- 本實作先使用深度展開網路產生初步高光譜結果：

$$Y_S \rightarrow Y_{DE}$$

- 其中 Y_{DE} 為由深度展開網路生成之「粗解」。

Step3: CNMF 後處理

- 使用 CNMF 對 Y_{DE} 進行修正。CNMF 將高光譜影像分解為：

$$Y_H^* = A \cdot S$$

- 用凸優化快速解出 A, S
- CNMF 的主要目的為：
 - 使 Y_H^* 接近深度展開網路輸出的 Y_{DE} 。
 - 使 Y_H^* 經 Sentinel-2 光譜響應矩陣 ($\tilde{D}$) 降維後，仍接近原始輸入 Y_S 。

Step4: 評估方式

- 分別訓練 simulation model 與 real Sentinel-2 model，並針對四種地貌進行比較：
 - coastline/lake
 - mountain
 - farm
 - city
- 每種地貌選取 5 張影像，共 20 張測試影像進行比較。評估指標包含：
 - PSNR：衡量整體重建誤差
 - SAM：衡量光譜曲線相似度
 - SSIM：衡量影像結構相似度
- 此外，本實作也透過重建影像與頻譜曲線，觀察模型是否能保留空間紋理與光譜特徵。

D. 實驗結果分析

本專題分別使用 simulation data 與 real Sentinel-2 data 進行實驗驗證，針對兩種資料設定進行實作與比較，以觀察模型在理想模擬條件與真實遙測資料下的差異。後續將針對 coastline/lake、mountain、farm 與 city 四種地貌類型，使用 PSNR、SAM 與 SSIM 評估重建結果。

	Dataset type	PSNR	SAM	SSIM
Coastline/lake	Simulation	40.512	3.098	0.981
	Real	29.404	8.275	0.816
Mountain	Simulation	44.921	1.815	0.987
	Real	30.063	4.620	0.793
Farm	Simulation	39.936	2.236	0.981
	Real	26.001	6.754	0.786
City	Simulation	38.109	2.577	0.973
	Real	28.325	5.724	0.736
Average	Simulation	40.867	2.398	0.981
	Real	28.448	6.343	0.783

Table 1 為 simulation data 與 real Sentinel-2 data 在四種地貌下的量化評估結果。整體而言，simulation data 在 PSNR 與 SSIM 上皆高於 real data，且 SAM 較低，代表模型在模擬資料上的重建效果較穩定；real data 的表現則相對下降，顯示真實資料的重建難度較高。




Fig. 1 顯示四種地貌類型下的 Y_H^* 重建影像結果。其中 (a) 為 simulation data，(b) 為 real Sentinel-2 data。由圖中可以看出，simulation data 的重建結果較穩定，而 real data 雖仍能保留主要地貌結構，但部分影像出現色彩差異與細節模糊。




Fig. 2 為每一小圖代表一張測試影像的平均頻譜，其中 (a) 為 simulation data，(b) 為 real Sentinel-2 data。黑線代表真實 AVIRIS (Y_H)，紅線代表重建結果 (Y_H^*)，藍色脈衝代表 Sentinel-2 輸入 (Y_S)。整體而言，simulation data 的重建頻譜較接近真實 AVIRIS，而 real data 在部分波段仍有較明顯落差。




Fig. 3 比較 Y_H 、 Y_S 、 Y_{DE} 與 Y_H^* 的視覺結果。其中左側為 simulation data，右側為 real Sentinel-2 data。可以觀察到 Y_{DE} 已能產生初步高光譜重建結果，而 Y_H^* 則為經 CNMF 後處理的最終輸出。

E. 結果討論

1. Simulation data 的整體表現明顯優於 real Sentinel-2 data

從 Table 1 可以看出，simulation data 的平均 PSNR 為 40.867 dB，高於 real data 的 28.448 dB；平均 SSIM 為 0.981，也高於 real data 的 0.783。另一方面，simulation data 的平均 SAM 為 2.398° ，低於 real data 的 6.343° 。這表示模型在 simulation data 下不論是像素重建、影像結構或光譜形狀上，皆有較穩定的表現。

2. 不同地貌的表現也有差異

在 simulation data 中，四種地貌的 PSNR 皆維持在 35 dB 以上，其中 mountain 的 PSNR 最高，為 44.921 dB，SAM 也最低，為 1.815° ，顯示模型在該類地貌上有較佳的重建效果。相較之下，city 的 PSNR 較低，為 38.109 dB，可能是因為城市區域包含建築物、道路、陰影與植被等多種地物，空間與光譜組成較複雜。在 real data 中，farm 的 PSNR 最低，為 26.001 dB，而 city 的 SSIM 最低，為 0.736，顯示真實資料中的複雜地物與配準誤差會進一步影響重建品質。

3. Real data 的重建難度較高

Real Sentinel-2 data 的三項指標皆低於 simulation data，除了真實 Sentinel-2 與 AVIRIS 來自不同感測器，可能存在影像配準誤差、空間解析度差異、光照條件差異與大氣校正問題外，另一個更重要的原因是，本專題無法取得拍攝時間完全一致的 AVIRIS/Sentinel-2 paired dataset。COS2A 原論文也指出，高品質資料配對需要找到兩種感測器在相同空間場景、相同時間取得的影像，且仍需進行多階段前處理，因此資料蒐集本身就是困難且耗時的工作。此外，原論文亦提到，要取得同一場景且同一時間的 AVIRIS/Sentinel-2 paired data 本身非常困難，還會受到兩者空間解析度非整數倍、飛行軌跡與方向不同等因素影響。因此，**real data 的量化指標較低**，應理解為真實遙測資料條件與配對限制下的結果，而不只是模型本身重建能力不足。

4. Y_{DE} 出現固定波段缺失會影響最終結果

在實作過程中，本專題發現即使整體影像視覺上看起來接近 ground truth，只要少數高光譜頻段出現明顯偏差或缺失，SAM 仍會顯著變差。這是因為 SAM 衡量的是整條光譜向量的角度，因此對光譜曲線形狀非常敏感。由於 Y_H^* 是以深度展開網路輸出的 Y_{DE} 為基礎，再經由 CNMF 後處理得到，若 Y_{DE} 本身在部分固定波段已經出現異常，CNMF 只能進行有限修正，難以完全恢復原本的光譜資訊。因此，少數波段異常雖然不一定明顯影響視覺結果，卻會顯著影響頻譜曲線與 SAM，也成為本專題後續調整 loss 設計的主要原因。

5. Loss 設計差異與實作調整

原始 COS2A 論文在訓練深度展開網路時，主要使用 ℓ_1 -loss，使網路輸出的粗略高光譜結果 Y_{DE} 接近真實 AVIRIS 影像 Y_H ：

$$\|Y_H - Y_{DE}\|_1$$

本專題初始實作時發現，若僅使用整體 ℓ_1 -loss，雖然能降低平均像素誤差，但少數固定波段仍可能出現預測不穩定或接近 0 的情況，進而使 SAM 明顯變差。因此，本專題在訓練中加入額外的光譜限制，使 loss 同時考慮波段誤差、光譜角度、頻譜連續性與輸出範圍：

$$\mathcal{L} = \mathcal{L}_{band-L1} + \alpha \mathcal{L}_{SAM} + \beta \mathcal{L}_{spec} + \gamma \mathcal{L}_{range}$$

其中， $\mathcal{L}_{band-L1}$ 用於避免少數波段被整體平均誤差掩蓋； $\mathcal{L}_{SAM}$ 用於改善光譜形狀； $\mathcal{L}_{spec}$ 用於維持相鄰波段的連續性； $\mathcal{L}_{range}$ 則避免模型輸出落在負值或不合理

範圍 α 、 β 、 γ 則為各項權重。此調整能降低固定波段異常對 Y_{DE} 與最終 Y_H^* 的影響。

6. 簡化版 CNMF 的效果與限制

原始 COS2A 論文中的 CNMF 流程較完整，包含更複雜的 spectral-spatial duality、Q-quadratic-norm regularization、minimum-volume constraint 與 abundance sparsity 等設計。但在本專題實作中，考量資料規模、程式可行性與重現難度，因此採用簡化版 CNMF 作為後處理。簡化版 CNMF 的核心仍保留原本精神：將高光譜影像表示為 $(Y_H^* = AS)$ ，並使結果同時接近深度網路輸出的 Y_{DE} 與 Sentinel-2 觀測資料 Y_S 。因此，它雖然不完全等同於論文原始方法，但仍能用來檢驗 CNMF 對重建結果的修正效果。

7. 整體結論

綜合量化指標與視覺化結果，本專題確認 COS2A 在 simulation data 下具有較佳重建能力，相較之下，在 real Sentinel-2 data 上仍受到資料差異與波段不穩定問題影響。未來若要提升真實資料表現，除了改善影像配準與前處理外，也需要持續優化 loss 設計與 CNMF 後處理，使模型能更穩定地重建完整光譜曲線。

F. 心得與未來展望

一年前，我第一次接觸 Deep Unfolding 技術時，就對這種結合最佳化演算法與深度學習的架構感到很有興趣。也很感謝老師提供 COS2A 這篇論文，讓我有機會從閱讀、理解到實作，完整地探索一個論文等級的方法。一開始閱讀論文時，其實很多內容都看不懂，包含最佳化問題、convex function、CNMF、深度學習架構，以及高光譜影像的資料形式，都需要從頭開始學習。為了更理解論文中的數學基礎，我也特別修習最佳化相關課程，從 convex set、convex function、norm、matrix factorization 等概念慢慢累積，才逐漸能理解論文中的方法設計。

在整個實作過程中，我覺得最困難的其實是資料處理階段。相較於理論或程式上的問題，許多資訊可以透過網路查詢資料，或是上課時更仔細理解來解決；但資料處理需要大量耐心與細心。為了建立可用的訓練資料，我不斷重新整理 dataset，檢查 AVIRIS 與 Sentinel-2 是否正確配對，並篩選掉黑邊、雲層、零值過多或配準不佳的影像。這個過程有時很枯燥，也容易因為一個小細節出錯而影響後續訓練結果。模型訓練也不是一次就完成，過程中因為 loss 設計、資料品質、CNMF 後處理與部分波段異常等問題，前

後重新訓練了將近十次。這讓我深刻體會到，**論文實驗不是只要把模型架構寫出來就好**，資料前處理、參數設定、評估方式與結果檢查，每一個細節都可能影響最後表現。

透過這次專題，我感受到**大學學習不應只停留在課本知識，實作能力與獨立思考同樣重要**。從一開始看不懂公式，到後來能完成資料處理、模型訓練、結果分析與報告撰寫，這個過程雖然花了很多時間，也遇到許多挫折，但最後能看到模型成功重建出高光譜影像，並完成一份完整的專題成果，我覺得非常有成就感。這次經驗也讓我更理解研究工作的實際樣貌：它需要耐心、反覆嘗試，以及面對問題時一步一步拆解的能力。對我來說，能把這個題目做到目前的成果，就是這一年學習與努力最重要的收穫。

G. 參考資料

- [1] **Chia-Hsiang Lin**, et al., “COS2A: Conversion from Sentinel-2 to AVIRIS hyperspectral data using interpretable algorithm with spectral-spatial duality,” *IEEE Transactions on Geoscience and Remote Sensing*, 2025.
- [2] C.-H. Lin, F. Ma, C.-Y. Chi, and C.-H. Hsieh, “A convex optimization based coupled nonnegative matrix factorization algorithm for hyperspectral and multispectral data fusion,” *IEEE Transactions on Geoscience and Remote Sensing*, vol. 56, no. 3, pp. 1652–1667, Nov. 2017.
- [3] N. Yokoya, T. Yairi, and A. Iwasaki, “Coupled nonnegative matrix factorization unmixing for hyperspectral and multispectral data fusion,” *IEEE Transactions on Geoscience and Remote Sensing*, vol. 50, no. 2, pp. 528–537, Aug. 2011.
- [4] Q. Ma, J. Jiang, X. Liu, and J. Ma, “Deep unfolding network for spatio-spectral image super-resolution,” *IEEE Transactions on Computational Imaging*, vol. 8, pp. 28–40, Dec. 2021.